

## מבוא למערכות לומדות תרגיל 4

עמית בסקין 312259013

### 1 למידות-PAC

1. יהיו  $A$  אלגוריתם למידה ו-  $\mathcal{D}$  התפלגות כלשהי.

נניח שפונקציית ה- Loss נמצאת בטווח  $[0, 1]$ .

צ. להוכיח ששתי הטענות הבאות שקולות:

• לכל  $\epsilon, \delta > 0$  יש  $m(\epsilon, \delta)$  כך שלכל  $m \geq m(\epsilon, \delta)$  מתקיים:

$$\mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S)) \leq \epsilon] \geq 1 - \delta$$

• מתקיים:

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] = 0$$

הוכחה:

כיוון ראשון: נניח שלכל  $\epsilon, \delta > 0$  יש  $m(\epsilon, \delta)$  כך שלכל  $m \geq m(\epsilon, \delta)$  מתקיים:

$$\mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S)) \leq \epsilon] \geq 1 - \delta$$

ונראה ש-

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] = 0$$

אכן:

יהא  $m \geq m(\epsilon, \delta)$ . ניקח  $\epsilon = \delta = \frac{1}{m}$ . נסמן  $x = L_{\mathcal{D}}(A(S))$ . נתבונן בפונקציית ההצטברות  $f(x)$  שמקיימת:

$$\mathbb{P}(a \leq x \leq b) = \int_a^b f(x) dx$$

נתון שפונקציית ה-Loss נמצאת בטווח  $[0, 1]$  ולכן זהו תחום האינטגרציה. אז נקבל:

$$\mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] = \int_0^1 x f(x) dx$$

נפצל לתחומים:

$$\begin{aligned} &= \int_0^{1/m} x f(x) dx + \int_{1/m}^1 x f(x) dx \leq \\ &\leq \frac{1}{m} \int_0^{1/m} f(x) dx + \int_{1/m}^1 f(x) dx \end{aligned}$$

אבל לכל  $a, b$  מתקיים:

$$\mathbb{P}(a \leq x \leq b) = \int_a^b f(x) dx \leq 1$$

ולכן:

$$\frac{1}{m} \int_0^{1/m} f(x) dx + \int_{1/m}^1 f(x) dx \leq \frac{1}{m} + \int_{1/m}^1 f(x) dx$$

ועתה מההנחה:

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[ L_{\mathcal{D}}(A(S)) \leq \frac{1}{m} \right] \geq 1 - \frac{1}{m}$$

נובע ש-

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[ L_{\mathcal{D}}(A(S)) > \frac{1}{m} \right] < \frac{1}{m}$$

קרי:

$$\frac{1}{m} + \int_{1/m}^1 f(x) dx < \frac{1}{m} + \frac{1}{m} = \frac{2}{m}$$

ניקח את  $m$  לאינסוף ונקבל:

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] = 0$$

כנדרש.

כיוון שני: נניח ש-

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] = 0$$

ונראה שלכל  $\epsilon, \delta > 0$  יש  $m(\epsilon, \delta)$  כך שלכל  $m \geq m(\epsilon, \delta)$  מתקיים:

$$\mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S)) \leq \epsilon] \geq 1 - \delta$$

אכן: יהיו  $\epsilon, \delta > 0$ . לפי א"ש מרקוב מתקיים:

$$\mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S)) \leq \epsilon] \leq \frac{\mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))]}{\epsilon}$$

עתה מההנחה ש-

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] = 0$$

אזי שקיים  $M$  כך שלכל  $m > M$  מתקיים ש-

$$\mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] \leq \epsilon(1 - \delta)$$

אז יהא  $m > M$  ונקבל:

$$\frac{\mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))]}{\epsilon} \leq \frac{\epsilon(1 - \delta)}{\epsilon} = 1 - \delta$$

קרי:

$$\mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S)) \leq \epsilon] \leq 1 - \delta$$

כלומר:

$$m(\epsilon, \delta) = M$$

מש"ל.

2. יהיו  $\mathcal{X} = \mathbb{R}^2, \mathcal{Y} = \{0, 1\}$  ו-  $\mathcal{H} = \{h_r \mid r \in \mathbb{R}_+\}$  מחלקה של היפותיזות כאשר  $h_r(x) = \mathbf{1}[\|x\|_2 \leq r]$ .

צלהוכיח ש-  $\mathcal{H}$  היא למידה-PAC וש-

$$m_{\mathcal{H}}(\epsilon, \delta) \leq \frac{\log(1/\delta)}{\epsilon}$$

הוכחה:

מהנחת הריאליזביליות יש  $h_r \in \mathcal{H}$  עם  $L_{\mathcal{D}}(h_r) = 0$ .

תהא  $S = \{(x_i, y_i)\}_{i=1}^m$  קבוצה של  $m$  דגימות שנדגמו באופן זהה ובלתי תלוי מהתפלגות  $\mathcal{D}$  מעל  $\mathcal{X} \times \mathcal{Y}$ .

נשים לב שמאחר ש-  $L_{\mathcal{D}}(h_r) = 0$  אזי ש-

$$\mathbb{P}_{(x,y) \sim \mathcal{D}} [\|x\|_2 > r \text{ and } y = 1] = 0$$

ניקח:

$$r_{alg} = \begin{cases} \max_{i \in [m]} \{\|x_i\|_2 \in \mathbb{R}_+ \mid y_i = 1\} & \exists i \in [m] (y_i = 1) \\ 0 & \text{else} \end{cases}$$

יהא  $r'$  ממשי אי-שלילי עם  $r' < r$  כך ש-

$$\mathbb{P}_{x \sim \mathcal{D}_X} [r' \leq \|x\|_2 \leq r] = \epsilon$$

ונשים לב שכדי שיתקיים  $L_{\mathcal{D}}(h_{r_{alg}}) \leq \epsilon$  מספיק שיתקיים ש-  $r_{alg} \geq r'$  כלומר:

$$\mathbb{P}[L_{\mathcal{D}}(h_{r_{alg}}) > \epsilon] \leq \mathbb{P}[r_{alg} < r']$$

אבל  $r_{alg} < r'$  אם  $(x_i, y_i) \in S$  מתקיים ש-  $\|x_i\|_2 \notin [r', r]$  קרי:

$$= \mathbb{P}_{S \sim \mathcal{D}^m} [\forall i \in [m] (\|x_i\|_2 \notin [r', r])] = (1 - \epsilon)^m \leq e^{-\epsilon m}$$

ומאחר שאנחנו מניחים ש-  $m > \frac{\log(1/\delta)}{\epsilon}$  אזי ש-

$$\leq e^{-\epsilon \frac{\log(1/\delta)}{\epsilon}} = e^{-\log(1/\delta)} = \frac{1}{e^{\log(1/\delta)}} = \frac{1}{1/\delta} = \delta$$

ומכאן ש-  $\mathcal{H}$  הינה למידה-PAC וכן:

$$m_{\mathcal{H}}(\epsilon, \delta) \leq \frac{\log(1/\delta)}{\epsilon}$$

■ כנדרש.

## 2 מימד VC

3. יהיו  $\mathcal{X} = \{0, 1\}^d$ ,  $\mathcal{Y} = \{0, 1\}$  עם  $d \geq 2$ .

כל דגימה  $(x, y) \in \mathcal{X} \times \mathcal{Y}$  מורכבת מהשמה של  $d$  משתנים בוליאניים ותויות.

לכל משתנה בוליאני  $x_k$  עם  $k \in [d]$  ישנם שני ליטרלים:  $x_k$  ו-  $\bar{x}_k = 1 - x_k$ .

נגדיר מחלקה  $\mathcal{H}_{\text{con}}$ : כל היפותזה ניתנת על ידי גימומים של תת-קבוצה כלשהי מתוך  $2d$  הליטרלים הנ"ל.

צ.לחשב את מימד ה-VC של  $\mathcal{H}_{\text{con}}$ .

תזכורות:

- תהא  $C \subseteq \mathcal{X}$ . הצמצום של  $\mathcal{H}$  ל-  $C$  הוא:

$$\mathcal{H}_C = \left\{ h_C \in \{0, 1\}^C \mid \exists h \in \mathcal{H} \text{ s.t. } \forall x \in C (h_C(x) = h(x)) \right\}$$

- נאמר ש-  $\mathcal{H}$  מנתצת קבוצה סופית  $C \subseteq \mathcal{X}$  אם  $|\mathcal{H}_C| = 2^{|C|}$ .

- הגדרנו:

$$\text{VC dim}(\mathcal{H}) = \sup \{m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} (|C| = m \text{ and } \mathcal{H} \text{ shatters } C)\}$$

- כדי להראות ש-  $\text{VC dim}(\mathcal{H}) = d$  צריך להראות ש-

- יש  $C \subseteq \mathcal{X}$  מגודל  $d$  שמנותצת על ידי  $\mathcal{H}$ , קרי  $\text{VC dim}(\mathcal{H}) \geq d$

- כל  $C \subseteq \mathcal{X}$  מגודל  $d+1$  אינה מנותצת על ידי  $\mathcal{H}$ , קרי  $\text{VC dim}(\mathcal{H}) \leq d$

פיתרון: נטען כי  $\text{VC dim}(\mathcal{H}) = d$ . הוכחה:

- $\text{VC dim}(\mathcal{H}) \geq d$ : ניקח את קבוצת הוקטורים הסטנדרטיים ב- $\mathbb{R}^d$ , קרי:  $C = \{e_i \in \mathbb{R}^d \mid i \in [d]\}$  ונראה שניתן לנתץ אותה על ידי  $\mathcal{H}$ :

אכן, יהא  $y \in \{0, 1\}^d$  וקטור תוויות עבור הוקטורים ב- $C$ . אז ניקח:

$$h = \bigwedge_{y_i=0} \overline{x_i}$$

ראשית לכל  $e_i \in C$  ולכל  $j \neq i$  מתקיים שהכניסה ה- $j$  ב- $e_i$  היא אפס, ומאחר שכל המשתנים בגימום של  $h$  הם ליטרליים שליליים אזי שההשמה של כניסה  $j$  ב- $e_i$  בתוך משתנה  $\overline{x_j}$  בגימום של  $h$  (אם הוא מופיע), נותן 1.

עתה, אם  $y_i = 1$  אז  $\overline{x_i}$  לא משתתף בגימום ובסה"כ מתקבל גימום של אחדות ולכן  $h(e_i) = 1$ . מצד שני אם  $y_i = 0$  אז  $\overline{x_i}$  משתתף בגימום ומקבל השמה של 0 ובסה"כ מתקבל גימום של אחדות ואפס ולכן  $h(e_i) = 0$ .

- $\text{VC dim}(\mathcal{H}) \leq d$ : תהא קבוצה  $C$  עם  $|C| = d+1$ . נניח בשלילה שניתן להתאים עבור  $C$  כל וקטור תוויות  $y$ . נמספר את הוקטורים ב-

$$C = \{c_i\}_{i=1}^{d+1}. \text{ אז בפרט לכל } c_i \text{ יש } h_C \text{ כך ש- } h_C^i(c_i) = 0 \text{ ולכל } j \neq i \text{ מתקיים } h_C^i(c_j) = 1.$$

לכל היפותיזה  $h_C^i$  כנ"ל, נבחר ליטרל  $z_i$  עליו  $c_i$  מקבל 0, קיים כזה כי  $h_C^i(c_i)$ .

נתבונן בקבוצת הליטרלים שקיבלנו:  $\{z_i\}_{i=1}^{d+1}$ . מעקרון שובך היונים יש שני ליטרלים  $z_i, z_j$  שמתייחסים לאותו משתנה. נחלק למקרים:

- אם  $z_i = z_j$  אז  $c_i, c_j$  שניהם מאפסים את  $z_i$  בסתירה לכך שאחד מהם אמור לקבל תיוג 0 והשני 1.

- אם  $z_i = \overline{z_j}$  בה"כ  $z_i = x_k$  ו- $z_j = \overline{x_k}$ . יהא  $l \notin \{i, j\}$ . אז  $l$  מקבל 1 גם  $x_k$  וגם על  $\overline{x_k}$  בסתירה.

מש"ל

### 3 PAC-אגנוסטיות

4. צלהוכיח שאם ל- $\mathcal{H}$  יש את תכונת ההתפלגות האחידה עם פונקציה

$$m_{\mathcal{H}}^{UC}: (0, 1)^2 \rightarrow \mathbb{N}$$

אז  $\mathcal{H}$  היא למידה-PAC-אגנוסטית עם סיבוכיות של

$$m_{\mathcal{H}}(\epsilon, \delta) \leq m_{\mathcal{H}}^{UC}\left(\frac{\epsilon}{2}, \delta\right)$$

תזכורת:

- קבוצת אימון  $S_m$  נקראת  $\epsilon$ -מייצגת עבור  $\mathcal{D}, \mathcal{H}, L$  אם לכל  $h \in \mathcal{H}$  מתקיים:  $|L_S(h) - L_{\mathcal{D}}(h)| < \epsilon$ .

- נאמר שלמחלקת היפותיזות  $\mathcal{H}$  יש את תכונת ההתכנסות האחידה אם יש  $m_{\mathcal{H}}^{UC}: (0, 1)^2 \rightarrow \mathbb{N}$  כך שלכל  $\epsilon > 0$  ו- $\delta < 1$  ולכל התפלגות  $\mathcal{D}$

$$\text{על } \mathcal{X} \times \mathcal{Y} \text{ מתקיים שאם } m \geq m_{\mathcal{H}}^{UC}(\epsilon, \delta) \text{ אז } \mathbb{P}(\{S_m \in (\mathcal{X} \times \mathcal{Y})^m \mid S \text{ is } \epsilon\text{-representative}\}) \geq 1 - \delta$$

• מחלקת היפותיזות  $\mathcal{H}$  נקראת למידה-PAC-אגנוסטית ביחס לפונקציית Loss  $L: \mathcal{H} \times (\mathcal{X} \times \mathcal{Y}) \rightarrow [0, \infty)$  אם קיימת פונקציה  $\tilde{m}_{\mathcal{H}}: (0, 1)^2 \rightarrow \mathbb{N}$  ואלגוריתם למידה  $\mathcal{A}_m: (\mathcal{X} \times \mathcal{Y})^m \rightarrow \mathcal{H}$  עם התכונה הבאה: לכל  $\epsilon, \delta \in (0, 1)$  ולכל התפלגות  $\mathcal{D}$  מעל  $\mathcal{X} \times \mathcal{Y}$  ולכל  $m \geq \tilde{m}_{\mathcal{H}}(\epsilon, \delta)$  מתקיים ש- $\mathbb{P} \left( \left\{ S_m \mid L_{\mathcal{D}}(h_{S_m}) \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon \right\} \right) \geq 1 - \delta$  כאשר  $S_m = \{(x_i, y_i)\}_1^m$  דגימות שנדגמו בצורה זהה ובלתי-תלויה מ- $\mathcal{D}$ , וכן  $h_{S_m} = \mathcal{A}_m(S_m)$ .

למה: תהא  $S_m$  קבוצת אימון  $\frac{\epsilon}{2}$ -מייצגת עבור  $\mathcal{D}, \mathcal{H}, L$ . תהא  $h_{S_m}$  פלט כלשהו של  $ERM_{\mathcal{H}}(S_m)$ , קרי  $h_{S_m} \in \arg \min_{h \in \mathcal{H}} L_{S_m}(h)$ . אז  $L_{\mathcal{D}}(h_{S_m}) < \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon$ .

הוכחה: מכך ש- $S_m$  היא  $\frac{\epsilon}{2}$ -מייצגת עבור  $\mathcal{D}, \mathcal{H}, L$ , אזי שלכל  $h \in \mathcal{H}$  מתקיים:

$$|L_{S_m}(h) - L_{\mathcal{D}}(h)| < \frac{\epsilon}{2} \implies \begin{cases} L_{S_m}(h) - L_{\mathcal{D}}(h) < \frac{\epsilon}{2} & \star_1 \\ L_{\mathcal{D}}(h) - L_{S_m}(h) < \frac{\epsilon}{2} & \star_2 \end{cases}$$

ובפרט זה מתקיים עבור  $h = h_{S_m}$ , אז מ- $\star_2$  נקבל:

$$L_{\mathcal{D}}(h_{S_m}) - L_{S_m}(h_{S_m}) < \frac{\epsilon}{2}$$

קרי:

$$L_{\mathcal{D}}(h_{S_m}) < L_{S_m}(h_{S_m}) + \frac{\epsilon}{2}$$

עתה ניקח  $h' \in \arg \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h)$ , ומאחר שב- $h'$  אילוץ המינימום חזק יותר, אזי ש-

$$\leq L_{S_m}(h') + \frac{\epsilon}{2}$$

ומ- $\star_1$  ב- $\epsilon/2$ -רפרסנטטיביות:

$$\leq L_{\mathcal{D}}(h') + \epsilon$$

כנדרש.

הוכחת השאלה המרכזית:

ל- $\mathcal{H}$  יש את תכונת ההתכנסות האחידה, קרי יש  $m_{\mathcal{H}}^{UC}: (0, 1)^2 \rightarrow \mathbb{N}$  כך שלכל  $\epsilon > 0$  ו- $\delta < 1$  ולכל התפלגות  $\mathcal{D}$  על  $\mathcal{X} \times \mathcal{Y}$  מתקיים ש- $\mathbb{P}(\{S_m \in (\mathcal{X} \times \mathcal{Y})^m \mid S \text{ is } \epsilon\text{-representative}\}) \geq 1 - \delta$  אם  $m \geq m_{\mathcal{H}}^{UC}(\epsilon, \delta)$ .

אז יהיו  $\epsilon, \delta \in (0, 1)$  וניקח  $m \geq m_{\mathcal{H}}^{UC}(\frac{\epsilon}{2}, \delta)$ .

מהלמה אנחנו יודעים ש- $S_m$  היא  $\frac{\epsilon}{2}$ -מייצגת אז  $L_{\mathcal{D}}(h_{S_m}) < \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon$ .

אז ממונוטוניות פונקציית ההסתברות נקבל ש-

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[ L_{\mathcal{D}} \left( h_{S_m} \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon \right) \right] \geq \mathbb{P} \left( \{S_m \in (\mathcal{X} \times \mathcal{Y})^m \mid S \text{ is } \frac{\epsilon}{2}\text{-representative}\} \right)$$

ומקיים תכונת ההתכנסות האחידה:

$$\geq 1 - \delta$$

כלומר קיבלנו את  $m_{\mathcal{H}}^{UC}: (0, 1)^2 \rightarrow \mathbb{N}$  מקיים תכונת ההתכנסות האחידה, ואלגוריתם הלמידה שלנו

$$\mathcal{A}_m: (\mathcal{X} \times \mathcal{Y})^m \rightarrow \mathcal{H}$$

הוא  $h_{S_m}$  והוא מקיים שלכל  $\epsilon, \delta \in (0, 1)$  ולכל התפלגות  $\mathcal{D}$  מעל  $\mathcal{X} \times \mathcal{Y}$  ולכל  $m \geq \tilde{m}_{\mathcal{H}}(\epsilon, \delta)$  מתקיים ש-

$$\mathcal{D}^m \left( \left\{ S_m \mid L_{\mathcal{D}}(h_{S_m}) \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon \right\} \right) \geq 1 - \delta$$

כאשר  $S_m = \{(x_i, y_i)\}_1^m$  דגימות שנדגמו בצורה זהה ובלתי-תלויה מ- $\mathcal{D}$ , וזוהי בדיוק ההגדרה של למידות-PAC-אגנוסטית. מש"ל

■

5. תהא  $\mathcal{H}$  מחלקת היפותיזות מעל  $Z = \mathcal{X} \times \{\pm 1\}$ .

נתבונן בפונקציית ההפסד 0-1.

נניח שיש פונקציה  $m_{\mathcal{H}}(\epsilon, \delta)$  כך שלכל התפלגות  $\mathcal{D}$  מעל  $Z$  יש אלגוריתם  $A$  עם התכונה הבאה:

כאשר מריצים את  $A$  על  $m \geq m_{\mathcal{H}}(\epsilon, \delta)$  דגימות שנדגמות בהתפלגות זהה ובאופן בלתי-תלוי שנקחות על ידי  $\mathcal{D}$ , אז מובטח ש- $A$

יחזיר עם הסתברות של לפחות  $1 - \delta$ , היפותיזה  $h_S: \mathcal{X} \rightarrow \{\pm 1\}$  עם  $L_{\mathcal{D}}(h_S) \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \epsilon$ .

צלבדוק האם  $\mathcal{H}$  היא למידה-PAC-אגנוסטית.

בחרתי לענות על שאלה 4.

## 4 מונוטוניות

6. תהא  $\mathcal{H}$  מחלקת היפותיזות עבור משימת קלסיפקציה בינארית.

נניח ש- $\mathcal{H}$  היא למידה-PAC ושהסיבוכיות ניתנת על ידי  $m_{\mathcal{H}}(\cdot, \cdot)$ .

צלהראות ש- $m_{\mathcal{H}}$  היא מונוטונית לא-עולה בכל אחד מהפרמטרים שלה, קרי בהינתן  $\delta \in (0, 1)$  ו- $0 < \epsilon_1 \leq \epsilon_2 < 1$  מתקיים ש-

$$m_{\mathcal{H}}(\epsilon_1, \delta) \geq m_{\mathcal{H}}(\epsilon_2, \delta)$$

ובהינתן  $\epsilon \in (0, 1)$  ו- $0 < \delta_1 \leq \delta_2 < 1$  מתקיים ש-

$$m_{\mathcal{H}}(\epsilon, \delta_1) \geq m_{\mathcal{H}}(\epsilon, \delta_2)$$

בחרתי לענות על שאלה 7.

7. יהיו  $\mathcal{H}_1, \mathcal{H}_2$  מחלקות של קלסיפקציה בינארית כך ש- $\mathcal{H}_1 \subseteq \mathcal{H}_2$ . צלהראות ש-

$$VC(\mathcal{H}_1) \leq VC(\mathcal{H}_2)$$

תזכורות:

• תהא  $C \subseteq \mathcal{X}$ . הצמצום של  $\mathcal{H}$  ל- $C$  הוא:

$$\mathcal{H}_C = \left\{ h_C \in \{0, 1\}^C \mid \exists h \in \mathcal{H} \text{ s.t. } \forall x \in C (h_C(x) = h(x)) \right\}$$

• נאמר ש- $\mathcal{H}$  מנתצת קבוצה סופית  $C \subseteq \mathcal{X}$  אם  $|\mathcal{H}_C| = 2^{|C|}$ .

• הגדרנו:

$$\text{VC dim}(\mathcal{H}) = \sup \{m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} (|C| = m \text{ and } \mathcal{H} \text{ shatters } C)\}$$

• כדי להראות ש- $\text{VC dim}(\mathcal{H}) = d$  צריך להראות ש-

- יש  $C \subseteq \mathcal{X}$  מגודל  $d$  שמנותצת על ידי  $\mathcal{H}$ , קרי  $\text{VC dim}(\mathcal{H}) \geq d$

- כל  $C \subseteq \mathcal{X}$  מגודל  $d+1$  אינה מנותצת על ידי  $\mathcal{H}$ , קרי  $\text{VC dim}(\mathcal{H}) \leq d$

הוכחת הטענה:

$$\text{VC dim}(\mathcal{H}_1) = \sup \{m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} (|C| = m \text{ and } \mathcal{H}_1 \text{ shatters } C)\} =$$

$$= \sup \{m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} (|C| = m \text{ and } |(\mathcal{H}_1)_C| = 2^m)\} =$$

$$= \sup \left\{ m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} \left( |C| = m \text{ and } \left| \left\{ h_C \in \{0,1\}^C \mid \exists h \in \mathcal{H}_1 \text{ s.t. } \forall x \in C (h_C(x) = h(x)) \right\} \right| = 2^m \right) \right\}$$

ומאחר ש- $\mathcal{H}_1 \subseteq \mathcal{H}_2$ :

$$\leq \sup \left\{ m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} \left( |C| = m \text{ and } \left| \left\{ h_C \in \{0,1\}^C \mid \exists h \in \mathcal{H}_2 \text{ s.t. } \forall x \in C (h_C(x) = h(x)) \right\} \right| = 2^m \right) \right\} =$$

$$= \sup \{m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} (|C| = m \text{ and } |(\mathcal{H}_2)_C| = 2^m)\} =$$

$$= \sup \{m \in \mathbb{N} \mid \exists C \subseteq \mathcal{X} (|C| = m \text{ and } \mathcal{H}_2 \text{ shatters } C)\} =$$

$$= \text{VC dim}(\mathcal{H}_2)$$

כנדרש.

## 5 טענה תיאורתית

8. יהא  $\mathcal{X}$  מרחב דגימות ו- $\mathcal{Y} = \{\pm 1\}$ .

תהא  $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$  מחלקת היפותיזות.

עבור  $C \subseteq \mathcal{X}$ , ניזכר בסימון  $\mathcal{H}_C$  עבור הצמצום של  $\mathcal{H}$  לקבוצה  $C$ .

נגדיר את הפונקציה  $\tau_m(\mathcal{H}) : \mathbb{N} \rightarrow \mathbb{N}$  שמתאימה ל- $\mathcal{H}$  על ידי:

$$\tau_{\mathcal{H}}(m) := \max \{|\mathcal{H}_C| \mid C \subseteq \mathcal{X} \text{ and } |C| = m\}$$



א. צ. להסביר מהי המשמעות של הפונקציה  $\tau_{\mathcal{H}}$ . הסבר:

ראשית, עבור  $|C| = m$  תמיד מתקיים ש-  $|\mathcal{H}_C| \leq 2^m$ , כי מספר התיוגים המקסימלי הוא  $2^m$ , קרי 0 או 1 לכל איבר ב-  $C$ . ולכן  $\tau_{\mathcal{H}}(m) \leq 2^m$  לכל  $m$ .

עתה, אם  $\tau_{\mathcal{H}}(m) = 2^m$  אז  $\text{VC dim}(\mathcal{H}) \geq m$  כי  $\tau_{\mathcal{H}}(m) = 2^m$  גורר שקיימת קבוצה מגודל  $m$  שניתנת לניתוח. כמו כן, אם  $\tau_{\mathcal{H}}(m) < 2^m$  אז  $\text{VC dim}(\mathcal{H}) < m$  כי זה שלא קיימת קבוצה מגודל  $m$  שניתנת לניתוח.

אם כן, במידה ש-  $\text{VC dim}(\mathcal{H}) < m$ , הפונקציה  $\tau_{\mathcal{H}}(m)$  יכולה לתת מושג עד כמה  $m$  רחוק מלהיות מימד ה-  $\text{VC}$  של  $\mathcal{H}$ . אם ההפרש בין  $\tau_{\mathcal{H}}(m)$  הוא "גדול" אז מימד ה-  $\text{VC}$  של  $\mathcal{H}$  "הרבה" יותר קטן מ-  $m$ , ואם ההפרש קטן אז מימד ה-  $\text{VC}$  של  $\mathcal{H}$  הוא "כמעט"  $m$ . ובמילים אחרות המספר  $\tau_{\mathcal{H}}(m)$  נותן את מספר ההיפותיזות המקסימלי האפשרי עבור תת-קבוצה מגודל  $m$  של קבוצת המדגם.

ב. נניח ש-  $\text{VC dim}(\mathcal{H}) = \infty$ . צ. למצוא ביטוי עבור הערך של  $\tau_{\mathcal{H}}(m)$  עבור  $m \in \mathbb{N}$ . פיתרון:

המשמעות של  $\text{VC dim}(\mathcal{H}) = \infty$  היא ש-  $\mathcal{H}$  מנתצת כל קבוצה מגודל  $m$  לכל  $m$  טבעי ולכן, בהסתמך על הסעיף הקודם, לכל  $m$  מתקיים ש-  $\tau_{\mathcal{H}}(m) = 2^m$ .

ג. נניח ש-  $\text{VC dim}(\mathcal{H}) = d$ . צ. למצוא ביטוי עבור הערך של  $\tau_{\mathcal{H}}(m)$  עבור  $m \leq d$ . פיתרון:

$d$  הוא הגודל המקסימלי של קבוצה ש-  $\mathcal{H}$  מנתצת, אז מכך ש-  $\text{VC dim}(\mathcal{H}) = d$  נובע שקיימת קבוצה  $C \subseteq \mathcal{X}$  עם  $|C| = d$  כך ש-  $|\mathcal{H}_C| = 2^d$ . ואז אם  $m \leq d$  אזי שכל קבוצה  $C'$  עם  $|C'| = m$  ו-  $C' \subseteq C$ , מתקיים ש-  $|\mathcal{H}_{C'}| = 2^m$  שהרי:

$$\mathcal{H}_C = \left\{ h_C \in \{0, 1\}^C \mid \exists h \in \mathcal{H} \text{ s.t. } \forall x \in C (h_C(x) = h(x)) \right\}$$

קרי אם יש  $h \in \mathcal{H}$  כך ש- לכל  $x \in C$  מתקיים ש-  $h_C(x) = h(x)$ , אז בפרט לכל  $x \in C' \subseteq C$   $h_{C'}(x) = h(x)$  ולכן אם מתקבלת כל קלסיפיקציה אפשרית עבור  $C$  אז בהכרח גם עבור  $C'$  ומכאן ש-

$$\tau_{\mathcal{H}}(m) = 2^m$$

מש"ל

ד. נניח ש-  $\text{VC dim}(\mathcal{H}) = d$ . יהא  $m > d$ . נראה ש-

$$\tau_{\mathcal{H}}(m) \leq \left( \frac{em}{d} \right)^d$$

עבור  $e$  בסיס הלוגריתם הטבעי. נעשה זאת בשלבים הבאים:

i. צ. להראות באינדוקציה שלכל  $C \subseteq \mathcal{X}$  סופית, מתקיים כי:

$$|\mathcal{H}_C| \leq |\{B \subseteq C \mid \mathcal{H} \text{ shatters } B\}|$$

הוכחה:

באינדוקציה על  $|C| = m$ :

בסיס האינדוקציה: עבור  $m = 1$ : יש איבר אחד ב-  $C$ .

אם ניתן לתייג אותו רק באפס או רק באחד אז  $|\mathcal{H}_C| = 1$  ואז הקבוצה היחידה שמוכלת ב-  $C$  ושמונתצת היא הקבוצה הריקה ולכן גם צד ימין שווה לאחד. אם ניתן לתייג את האיבר ב-  $C$  גם באפס וגם באחד אז צד שמאל בא"ש שווה לשתיים ואז ניתן לנתץ גם את  $C$  עצמה וגם את הקבוצה הריקה ולכן גם צד ימין הוא 2. מש"ל בסיס האינדוקציה.

צעד: נניח שהטענה נכונה לכל  $k < m$  עבור  $m > 1$  ונוכיח עבור  $m$ : נמספר את האיברים ב- $C$ :  $C = \{c_i\}_1^m$  וכן נגדיר  $C' = \{c_i\}_2^m$ .

כמו כן נגדיר:

$$Y_0 = \{(y_2, \dots, y_m) \mid (0, y_2, \dots, y_m) \in \mathcal{H}_C \vee (1, y_2, \dots, y_m) \in \mathcal{H}_C\}$$

$$Y_1 = \{(y_2, \dots, y_m) \mid (0, y_2, \dots, y_m) \in \mathcal{H}_C \wedge (1, y_2, \dots, y_m) \in \mathcal{H}_C\}$$

נשים לב שמתקיים כי  $Y_1 \subseteq Y_0$  כי לכל  $(y_2, \dots, y_m)$  עם  $(0, y_2, \dots, y_m) \in \mathcal{H}_C \wedge (1, y_2, \dots, y_m) \in \mathcal{H}_C$  בפרט מתקיים ש- $(0, y_2, \dots, y_m) \in \mathcal{H}_C \vee (1, y_2, \dots, y_m) \in \mathcal{H}_C$ . כמו כן, לכל  $(y_2, \dots, y_m) \in Y_1$  מתקיים ש- $(0, y_2, \dots, y_m) \in \mathcal{H}_C$  וגם  $(1, y_2, \dots, y_m) \in \mathcal{H}_C$  ולכל  $(y_2, \dots, y_m) \in Y_0 \setminus Y_1$  מתקיים ש- $(0, y_2, \dots, y_m) \in \mathcal{H}_C$  XOR  $(1, y_2, \dots, y_m) \in \mathcal{H}_C$  ולכן  $|\mathcal{H}_C| = 2|Y_1| + |Y_0 \setminus Y_1| = |Y_0| + |Y_1|$ .

עבור היפותיזה  $h_C \in \mathcal{H}_C$  שנותנת את התווית  $y_i$  עבור  $c_i$ , נסמן:  $h_C = (y_1, y_2, \dots, y_m)$  ובאופן דומה נסמן גם עבור  $h_{C'} \in \mathcal{H}_{C'}$  אם כן, על פי ההגדרה מתקיים:

$$\begin{aligned} \mathcal{H}_{C'} &= \{h_{C'} \in \{0, 1\}^{C'} \mid \exists h_C \in \mathcal{H}_C \text{ s.t. } \forall x \in C' (h_{C'}(x) = h_C(x))\} = \\ &= \{(y_2, \dots, y_m) \in \{0, 1\}^{C'} \mid (0, y_2, \dots, y_m) \in \mathcal{H}_C \vee (1, y_2, \dots, y_m) \in \mathcal{H}_C\} = Y_0 \end{aligned}$$

אז מהנחת האינדוקציה:

$$|Y_0| = |\mathcal{H}_{C'}| \leq |\{B \subseteq C' \mid \mathcal{H} \text{ shutters } B\}|$$

אבל  $C' = C \setminus \{c_1\}$  ולכן:

$$= |\{B \subseteq C \mid \mathcal{H} \text{ shutters } B \text{ and } c_1 \notin B\}|$$

נגדיר  $\mathcal{H}' \subseteq \mathcal{H}$  על ידי:

$$\mathcal{H}' = \{h \in \mathcal{H} \mid \exists h' \in \mathcal{H} \text{ s.t. } (1 - h'(c_1), h'(c_2), \dots, h'(c_m)) = (h(c_1), h(c_2), \dots, h(c_m))\}$$

ונשים לב ש-

$$\begin{aligned} \mathcal{H}_{C'} &= \{h_{C'} \in \{0, 1\}^{C'} \mid \exists h' \in \mathcal{H}' \text{ s.t. } \forall x \in C' (h_{C'}(x) = h'(x))\} = \\ &= \{h_{C'} \in \{0, 1\}^{C'} \mid \exists h \in \mathcal{H}' \text{ s.t. } \exists h' \in \mathcal{H} \text{ s.t. } (1 - h'(c_1), h'(c_2), \dots, h'(c_m)) = (h(c_1), h(c_2), \dots, h(c_m)) \text{ and } \forall x \in C' (h_{C'}(x) = h(x))\} = \\ &= \{(y_2, \dots, y_m) \in \{0, 1\}^{C'} \mid (\overline{y_1}, y_2, \dots, y_m) \in \mathcal{H}_C \wedge (y_1, y_2, \dots, y_m) \in \mathcal{H}_C\} = Y_1 \end{aligned}$$

אז מהנחת האינדוקציה נקבל ש-

$$|Y_1| = |\mathcal{H}'_{C'}| \leq |\{B \subseteq C' \mid \mathcal{H}' \text{ shutters } B\}|$$

אבל לכל  $(y_2, \dots, y_m) \in \mathcal{H}'_{C'}$  מתקיים ש-  $(\overline{y_1}, y_2, \dots, y_m) \in \mathcal{H}_C \wedge (y_1, y_2, \dots, y_m) \in \mathcal{H}_C$  ולכן אם  $\mathcal{H}'$  מנתצת את  $B$  אז היא מנתצת גם את  $B \cup \{c_1\}$ , קרי:

$$= |\{B \subseteq C' \mid \mathcal{H}' \text{ shutters } B \cup \{c_1\}\}| =$$

$$= |\{B \subseteq C' \mid \mathcal{H}' \text{ shutters } B \text{ and } c_1 \in B\}|$$

ומאחר ש-  $\mathcal{H}' \subseteq \mathcal{H}$ :

$$\leq |\{B \subseteq C' \mid \mathcal{H} \text{ shutters } B \text{ and } c_1 \in B\}|$$

ולבסוף:

$$|\mathcal{H}_C| = |Y_0| + |Y_1| \leq$$

$$\leq |\{B \subseteq C \mid \mathcal{H} \text{ shutters } B \text{ and } c_1 \notin B\}| + |\{B \subseteq C' \mid \mathcal{H} \text{ shutters } B \text{ and } c_1 \in B\}| =$$

$$= |\{B \subseteq C \mid \mathcal{H} \text{ shutters } B\}|$$

כנדרש. ■

ii. צ.להסביר את המשמעות של אי־השוויון הנ"ל. הסבר:

אם יש ב-  $\mathcal{H}_C$   $m$  היפותיזות אז יש ב-  $C'$  לפחות  $m$  תת־קבוצות ש-  $\mathcal{H}$  מנתצת אותן.

iii. צ.להראות שלכל קבוצה סופית  $C \subseteq \mathcal{X}$ , מתקיים:

$$|\{B \subseteq C \mid \mathcal{H} \text{ shutters } B\}| \leq \sum_{k=0}^d \binom{m}{k}$$

הוכחה:

נתון ש-  $\text{VCdim}(\mathcal{H}) = d$  ולכן  $\mathcal{H}$  יכולה לנתץ רק קבוצות שהן מגודל  $d$  ומטה. אז כל הקבוצות ב-  $C$  ש-  $\mathcal{H}$  יכולה לנתץ הן תת־קבוצות מגודל שהוא קטן או שווה ל-  $d$ . אז לכל  $k \leq d$ , יש  $\binom{m}{k}$  תת־קבוצות ב-  $C$  שהן מגודל  $k$ , ולכן מתקיים הא"ש הנ"ל.

iv. צ.להשתמש באי־השוויון הבא:

$$\sum_{k=0}^d \binom{m}{k} \leq \left(\frac{em}{d}\right)^d$$

כדי לסיים את ההוכחה ש-

$$\tau_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d$$

הוכחה:

$$\tau_{\mathcal{H}}(m) := \max \{ |\mathcal{H}_C| \mid C \subseteq \mathcal{X} \text{ and } |C| = m \}$$

ומאחר שהטענות שהוכחנו לעיל נכונות לכל  $C$  מגודל  $m$ :

$$\leq \max \{ |\{B \subseteq C \mid \mathcal{H} \text{ shutters } B\}| \mid C \subseteq \mathcal{X} \text{ and } |C| = m \} \leq$$

$$\leq \sum_{k=0}^d \binom{m}{k}$$

ומאחר ש-  $m > d + 1$ :

$$\leq \left(\frac{em}{d}\right)^d$$

■ כנדרש.

ה. נניח ש-  $m = d$ . צלבדוק האם מתקיים הא"ש  $\tau_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d$ . אם כן, האם הוא הדוק? פיתרון:

הא"ש נשמר כי:

$$\tau_{\mathcal{H}}(m) = \tau_{\mathcal{H}}(d) = 2^d \leq e^d = \left(\frac{ed}{d}\right)^d = \left(\frac{em}{d}\right)^d$$

וככל ש-  $d$  גדול יותר, כך החסם יותר הדוק כי ככל ש-  $d$  גדל כך קטן ההפרש  $e^d - 2^d = (e - 2)^d \approx (0.718)^d$ .

ו. צלאפיין במילים את ההתנהגות של  $\tau_{\mathcal{H}}(m)$  עבור  $m \leq \text{VC dim}(\mathcal{H})$  ועבור  $m > \text{VC dim}(\mathcal{H})$ , ולהשתמש בו כדי להציע הגדרה אלטרנטיבית עבור  $\text{VC dim}(\mathcal{H})$ . פיתרון:

עבור  $m > \text{VC dim}(\mathcal{H})$  מתקיים ש-  $\tau_{\mathcal{H}}(m) < 2^m$ , קרי מתקבלת התנהגות פולינומיאלית ועבור  $m \geq \text{VC dim}(\mathcal{H})$  מתקיים  $\tau_{\mathcal{H}}(m) = 2^m$  קרי מתקבלת התנהגות אקספוננציאלית.


מכאן נובע שאם גרף הפונקציה של  $\tau_{\mathcal{H}}(m)$  הוא אקספוננציאלי ב-  $m$  תמיד, אז  $\mathcal{H}$  אינה למידה-PAC כי אז  $\text{VC dim}(\mathcal{H}) = \infty$ , ואילו אם הגרף של  $\tau_{\mathcal{H}}(m)$  הינו פולינומי החל ממקום מסוים אזי ש-  $\mathcal{H}$  הינה למידה-PAC כי מתקיים ש-  $\text{VC dim}(\mathcal{H}) < \infty$ . אז נוכל להגדיר:

$$\text{VC dim}(\mathcal{H}) = \min \{ m \in \mathbb{N} \mid \tau_{\mathcal{H}}(m) < 2^m \}$$

ואז אם נסמן ב-  $\widehat{\text{VC dim}}(\mathcal{H})$  את מימד ה-VC לפי ההגדרה החדשה, אז נקבל ש-  $\widehat{\text{VC dim}}(\mathcal{H}) = \text{VC dim}(\mathcal{H}) + 1$  כאשר  $\text{VC dim}(\mathcal{H}) < \infty$  והוא מימד ה-VC לפי ההגדרה המקורית:  $\widehat{\text{VC dim}}(\mathcal{H}) = d$  אזי שכל קבוצה מגודל  $d$  ומעלה לא ניתנת לניתוח ואילו  $d - 1$  ניתנת לניתוח ולכן  $\text{VC dim}(\mathcal{H}) = d$  מש"ל.

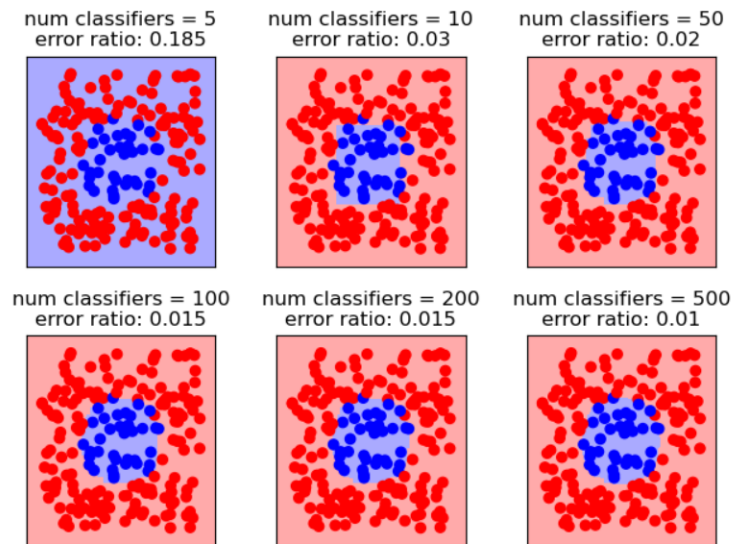
## 6 להפריד את הבלתי ניתן להפרדה - Adaboost

.10



.11


An Adaboost classifier based on a DecisionStump weak learner  
using different amounts of weak learners  
over the test data which consists of 200 samples  
with zero noise



.12. בשאלה הקודמת ניתן לראות ש-  $T = 500$  ממזער את השגיאה עבור ה- test set.

An Adaboost classifier based on a DecisionStump weak learner  
over the training data which consists of 5,000 samples  
with zero noise


num classifiers = 500  
error ratio = 0.0



.13

The training set of an Adaboost classifier  
with size proportional to the transpose of the weights  
of the samples in the last iteration of the training  
with 5,000 training samples  
with zero noise

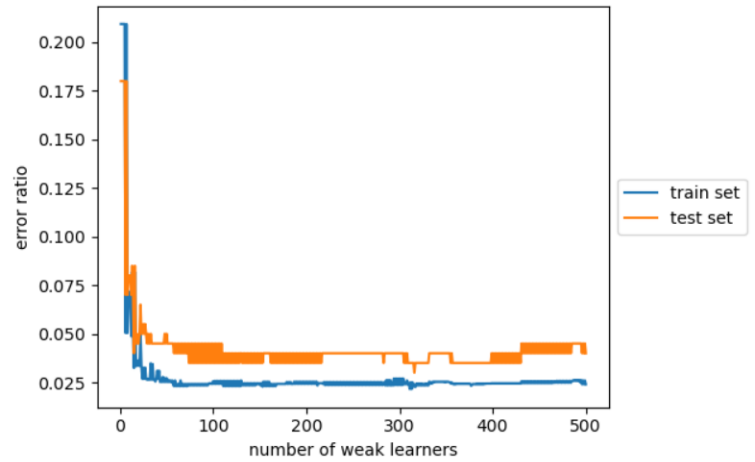
num classifiers = 500  
error ratio = 0.0002



בשוליים של העיגול הנקודות גדולות יותר כי האלגוריתם טעה עליהן הרבה פעמים במהלך תהליך הלמידה ולכן הוא נתן להן משקל גדול יותר מנקודות באזורים אחרים. וזאת משום שקשה לסווג את השוליים באמצעות חלוקות אופקיות ואנכיות בלבד. כמו כן, הנקודות מחוץ לעיגול קטנות יותר כי האלגוריתם טעה עליהן פחות באופן יחסי, ולכן נתן להן משקל קטן יותר. וזאת משום שקל יותר לסווג אותן על ידי חלוקות אופקיות ואנכיות.


.14

error ratio of an Adaboost classifier  
based on a DecisionStump weak learner,  
as a function of the number of weak learners  
the samples are taken with 0.01 noise




An Adaboost classifier based on a DecisionStump weak learner  
using different amounts of weak learners  
over the test data which consists of 200 samples  
with 0.01 noise


num classifiers = 5  
error ratio = 0.18




num classifiers = 10  
error ratio = 0.08




num classifiers = 50  
error ratio = 0.05




num classifiers = 100  
error ratio = 0.035



num classifiers = 200  
error ratio = 0.035




num classifiers = 500  
error ratio = 0.04




An Adaboost classifier based on a DecisionStump weak learner  
over the training data which consists of 5,000 samples  
with 0.01 noise

num classifiers = 100  
error ratio = 0.0256



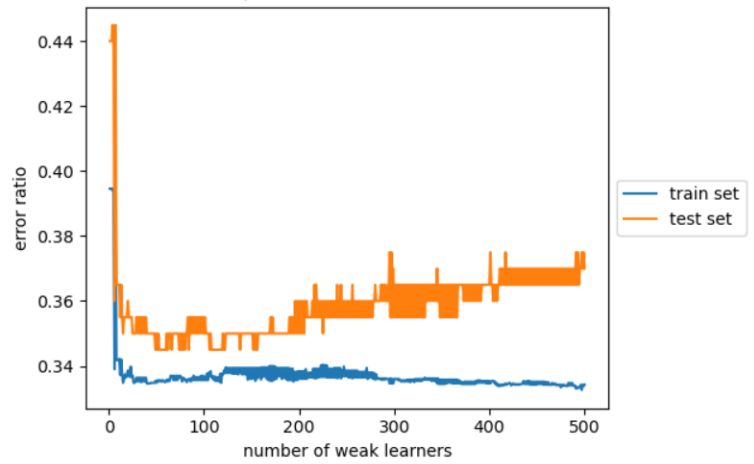
The training set of an Adaboost classifier  
with size proportional to the transpose of the weights  
of the samples in the last iteration of the training  
with 5,000 training samples  
with 0.01 noise

num classifiers = 500  
error ratio = 0.024






error ratio of an Adaboost classifier  
based on a DecisionStump weak learner,  
as a function of the number of weak learners  
the samples are taken with 0.4 noise




An Adaboost classifier based on a DecisionStump weak learner  
using different amounts of weak learners  
over the test data which consists of 200 samples  
with 0.4 noise




An Adaboost classifier based on a DecisionStump weak learner  
over the training data which consists of 5,000 samples  
with 0.4 noise

num classifiers = 50  
error ratio = 0.3348



The training set of an Adaboost classifier  
with size proportional to the transpose of the weights  
of the samples in the last iteration of the training  
with 5,000 training samples  
with 0.4 noise

num classifiers = 500  
error ratio = 0.3342



### הסבר כללי לשינויים:

כשהרעש יחסית קטן, קרי 0.01, ניתן לראות שהשגיאה בסיווג היא יחסית קטנה ומספר המסווגים האופטימלי הוא עדיין המקסימלי מבין האפשרויות, וכשהרעש יחסית גדול, קרי 0.4, ניתן לראות שהשגיאה גדלה משמעותית, וכך גם מספר המסווגים האופטימלי מבין האפשרויות, נעשה קטן יותר באופן משמעותי.

### הסבר של השינויים ביחס לשאלה 10:

ככל שהדאטא נתון עם יותר רעש, כך bias קטן יותר, קרי שימוש במספר גדול של לומדים חלשים, גורם להתאמת-יתר חמורה יותר, קרי variance גדול יותר. לכן ככל שהרעש גדל כך ניתן לראות שהשגיאה קבוצת המבחן גדלה, והפער בין מידת השגיאה בקבוצת האימון ובין השגיאה בקבוצת המבחן, גדל.

### הסבר של השינויים ביחס לשאלה 12:

בהסתמך על ההסבר שנתתי לעיל עבור השינויים ביחס לשאלה 10, נובע שנרצה להשתמש בפחות לומדים חלשים על מנת להקטין את ה־ variance, ואכן כשהרעש יחסית גדול, קרי 0.4, נקבל שגיאה מינימלית עבור 50 מסווגים ולא עבור 500 כמו במקרה ללא הרעש.